



北京邮电大学数学科学学院





第六章 样本及抽样分布

6.1 随机样本

6.2 直方图和箱线图

6.3 抽样分布





从历史典籍中，人们不难发现许多关于钱粮、户口、地震、水灾等记载，说明人们很早就开始了统计工作。但是当时的统计，只是对有关事实的简单记录和整理，而没有在一定理论的指导下，作出超越这些数据范围之外的推断。

到了十九世纪末二十世纪初，随着近代数学和概率论的发展，才真正诞生了数理统计学这门学科。

在数理统计中，不是对所研究的对象全体(称为**总体**)进行观察，而是抽取其中的部分(称为**样本**)进行观察获得数据（**抽样**），并通过这些数据对总体进行推断.


数理统计所要研究的问题：

(1)怎样设计试验，决定观察的数目；


(2)怎样利用试验观察的结果作出一个“好”的推断等.

第一个问题是怎样进行抽样，使抽得的样本更合理,并有更好的代表性？这是抽样方法和试验设计问题：最简单易行的是进行**随机抽样**.

第二个问题是怎样从取得的样本去推断总体？这种推断具有多大的可靠性？这是**统计推断(核心)**问题.




统计方法具有“部分推断整体”的特征。



引例 某公司要采购一批产品，每件产品不是合格品就是不合格品，该批产品总有一个不合格品率 p 。由此，若从该批产品中随机抽取一件，用 x 表示产品的不合格数，不难看出 x 服从一个二点分布 $b(1, p)$ ，但分布中的参数 p 是不知道的。一些问题：

- p 的大小如何；
- p 大概落在什么范围内；
- 能否认为 p 满足设定要求（如 $p \leq 0.05$ ）。



数理统计学是一门关于数据收集、整理、分析和推断的科学。

§6.1 随机样本

一个问题总有明确的研究对象和数量指标，对其做试验或观察.

研究对象的全部可能得观察值称为**总体**，

总体中每个成员称为**个体**

总体中所包含的个体的个数称为总体的**容量**.



总体 {
有限总体
无限总体

研究某批灯泡的质量

由于每个个体观测结果是随机的，所以相应的数量指标的出现也带有随机性。从而**可以把这种数量指标看作一个随机变量 X** ，随机变量 X 的分布是该数量指标在总体中的分布.今后不做区分，统称为总体。

例1 考察某厂的产品质量，以0记合格品，以1记不合格品，则

总体 = {该厂生产的全部合格品与不合格品}
= {由0或1组成的一堆数}

若以 p 表示这堆数中1的比例（不合格品率），则该总体可由一个二点分布表示：
不同的 p 反映总体的差异。

X	0	1
P	$1 - p$	p

X	0	1
p	0.983	0.017

X	0	1
p	0.915	0.085

例2 在二十世纪七十年代后期，美国消费者购买日产SONY彩电的热情高于购买美产SONY彩电，原因何在？

原因在于总体的差异上！

➤ 1979年4月17日日本《朝日新闻》刊登调查报告指出 $N(m, (5/3)^2)$ ，日产SONY彩电的彩色浓度服从正态分布，美产SONY彩电的彩色浓度服从 $(m-5, m+5)$ 上的均匀分布。




图6.1.1 SONY彩电彩色浓度分布图

表6.1.1 各等级彩电的比例(%)

等级	I	II	III	IV
美产	33.3	33.3	33.3	0
日产	68.3	27.1	4.3	0.3

然而，在实际操作中，不是对所研究的对象全体(称为**总体**)进行观察，而是抽取其中的部分(称为**样本**)进行观察获得数据（**抽样**），并通过这些数据对总体进行推断。

由于推断是基于抽样数据，抽样数据又不能包括研究对象的全部信息。因而由此获得的结论必然包含不肯定性。

所以应记住毕竟是由“**局部**”推断“**整体**”，因而仍可能犯错误，结论往往又是在某个“**可靠性水平**”之下得出的。

这种矛盾的特殊性与普遍性的辩证统一在统计学中贯穿始终，是我们应该记住的基本思想。

6.1.2 样本

样本的定义

为了了解总体的分布，我们从总体中随机地抽取 n 个个体，记为 $X_1, X_2, \dots, X_n$,

则 $X_1, X_2, \dots, X_n$ 称为总体的一组样本， n 称为**样本容量**，或简称**样本量**；

它们的观测值 $x_1, x_2, \dots, x_n$ 称为**样本值**。

例3 啤酒厂生产的瓶装啤酒规定净含量为640克。由于随机性，事实上不可能使得所有的啤酒净含量均为640克。现从某厂生产的啤酒中随机抽取10瓶测定其净含量，得到如下结果：

641, 635, 640, 637, 642, 638, 645, 643, 639, 640

这是一个容量为10的样本的观测值，对应的总体为该厂生产的所有瓶装啤酒的净含量。

样本的要求：简单随机样本

要使得推断可靠，对样本就有要求，使样本能很好地代表总体。我们在相同条件下对总体进行重复、独立的观察，通常有如下两个要求：

随机性：总体中每一个个体都有同等机会， X_i 与总体 X 有相同的分布。

独立性：样本中每一样品的取值不影响其它样品的取值， $X_1, X_2, \dots, X_n$ 相互独立。

于是, 样本 $x_1, x_2, \dots, x_n$ 可以看成是独立同分布(*iid*) 的随机变量, 其共同分布即为**总体分布**。

设总体 X 具有分布函数 $F(x)$, $X_1, X_2, \dots, X_n$ 为取自该总体的容量为 n 的样本, 则样本**联合分布函数**为

$$F(x_1, \dots, x_n) = \prod_{i=1}^n F(x_i).$$

实际中总体中的个体数大多是有限的。当个体数充分大时，将有限总体看作无限总体是一种合理的抽象。

对无限总体，随机性与独立性容易实现，困难在于排除有意或无意的人为干扰。

对有限总体，只要总体所含个体数很大，特别是与样本量相比很大，则独立性也可基本得到满足。

例 设有一批产品共 N 个，需要进行抽样检验以了解其不合格品率 p 。现从中采取不放回抽样抽出2个产品，这时，第二次抽到不合格品的概率依赖于第一次抽到的是否是不合格品，如果第一次抽到不合格品，则

$$P(x_2 = 1 \mid x_1 = 1) = (Np - 1) / (N - 1)$$

而若第一次抽到的是合格品，则第二次抽到不合格品的概率为

$$P(x_2 = 1 \mid x_1 = 0) = (Np) / (N - 1)$$

显然，如此得到的样本不是简单随机样本。但是，当 N 很大时，我们可以看到上述两种情形的概率都近似等于 p 。所以当 N 很大，而 n 不大（一个经验法则是 $n / N \leq 0.1$ ）时可以把该样本近似地看成简单随机样本。

即：一般对有限总体，采用放回抽样所得到的样本为简单随机样本，但使用不方便，常用不放回抽样代替。而代替的条件是 $N/n \geq 10$

其中 N 为总体中个体的数目， n 为样本容量。

§6.2 直方图与箱线图



直方图

设对总体 X 作 n 次观测, 其样本值 $x_1, x_2, \dots, x_n$. 作

频率直方图可分为以下几个步骤:

(1) 找出这 n 个数的最小和最大值:

$$X_{(1)} = \min_{1 \leq i \leq n} X_i, \quad X_{(n)} = \max_{1 \leq i \leq n} X_i.$$

(2) 取区间 $[a, b]$, 使得 a 略小于 $X_{(1)}$, b 略大于 $X_{(n)}$; 从中插入 $k-1$ 个分点

$$a = a_0 < a_1 < \dots < a_k = b,$$

把 $[a, b]$ 分成 k 个小区间

$$(a_0, a_1], (a_1, a_2], \dots, (a_{k-1}, a_k],$$

称 $\Delta a_i = a_i - a_{i-1}$ 为第 i 组组距, $\frac{a_i + a_{i-1}}{2}$ 为第 i 组组中值. 各组距可以相等, 也可以不等. 子区间的个数不宜太多或太少. **需要注意的是**, a_i 的取值可比观测值多一位小数, 这样可避免观测值落在每组的分点上.

(3) 记 n_i 为落在小区间 $(a_{i-1}, a_i]$ 中观察值的个数(频数), 计算频率 $f_i = \frac{n_i}{n}$, $i = 1, 2, \dots, k$. 列表分别记下各小区间的频数、频率.

(4) 在直角坐标系的横轴上, 标出 $a_0, a_1, \dots, a_k$ 各点, 分别以 $(a_{i-1}, a_i]$ 为底边, 作高为 f_i 的矩形($i = 1, 2, \dots, k$), 即得频率直方图.

• **例3** 某工厂用自动包装机包装产品，为了考察每袋产品重量的波动情况，选取100袋产品测得其重量如下：(单位：kg)，根据测得的数据作出频率直方图。

- 97.8 94.6 98.9 100.9 99.8 102.7 97.9
- 95.5 99.0 101.1 99.6 102.9 97.7 95.7
- 99.5 101.2 99.9 103.1 98.2 95.8 99.1
- 101.3 100.0 103.8 98.1 96.0 99.0 101.4
- 100.1 98.3 96.3 99.2 101.5 100.2 104.5
- 98.5 96.6 99.3 101.4 100.3 97.8 98.4
- 96.7 99.4 101.1 100.4 96.9 99.5 101.0
- 100.1 98.5 97.0 99.1 101.2 100.2 98.0
- 97.2 99.2 101.6 100.2 98.1 97.4 99.0
- 101.6 100.4 98.1 97.5 99.4 101.8 100.5
- 98.7 97.1 99.3 102.1 100.3 98.8 99.9
- 98.9 102.0 100.2 98.9 99.7 100.6 102.1
- 100.4 98.8 99.6 100.6 102.3 100.1 98.6
- 99.7 100.7 102.4 98.8 99.8 102.2 100.8
- 99.8 100.9

解 (1) 在全部数据中找出最小值 $m = 94.6$,
最大值 $M = 104.5$.

(2) 取 $a = 94.55$, $b = 104.55$, 并确定组数、
组距

本例分为 $k = 10$ 组, 因 $\frac{M - m}{k} = 0.99$, 组距
可取 $d = 1$, 并采用等距分组法.

(3) 作出频数、频率分布表，如下表所示.

组序	组 区 间	频数	频率	累积频率
1	94.55 ~ 95.55	2	0.02	0.02
2	95.55 ~ 96.55	4	0.04	0.06
3	96.55 ~ 97.55	8	0.08	0.14
4	97.55 ~ 98.55	13	0.13	0.27
5	98.55 ~ 99.55	21	0.21	0.48
6	99.55 ~ 100.55	23	0.23	0.71
7	100.55 ~ 101.55	15	0.15	0.86
8	101.55 ~ 102.55	9	0.09	0.95
9	102.55 ~ 103.55	3	0.03	0.98
10	103.55 ~ 104.55	2	0.02	1.00

(4) 作出频率及累积频率直方图，如图 1， 2.




图 1




图 2

箱线图--- 样本分位数与样本中位数

设 $x_{(1)}, \dots, x_{(n)}$ 是有序样本，则样本中位数 $m_{0.5}$ 定义为

$$m_{0.5} = \begin{cases} X_{(\frac{n+1}{2})} & n \text{ 为奇数} \\ \frac{1}{2} (X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}) & n \text{ 为偶数} \end{cases}$$

譬如，若 $n=5$ ，则 $m_{0.5}=x_{(3)}$ ， $n=6$ ，则 $m_{0.5} = \frac{1}{2} (x_{(3)} + x_{(4)})$ 。


更一般地，样本 p 分位数 m_p 可如下定义：

$$m_p = \begin{cases} x_{([np+1])}, & \text{若 } np \text{ 不是整数} \\ \frac{1}{2} (x_{(np)} + x_{(np+1)}), & \text{若 } np \text{ 是整数} \end{cases}$$

通常，样本均值在概括数据方面具有一定的优势。但当数据中含有极端值时，使用中位数比使用均值更好，中位数的这种抗干扰性在统计中称为具有**稳健性**。

箱线图--- 样本分位数与样本中位数

箱线图是基于以下5个数的图形概括：



下表是某厂160名销售人员某月的销售数据的有序样本，

45	74	76	80	87	91	92	93	95	96
98	99	104	106	111	113	117	120	122	122
124	126	127	127	129	129	130	131	131	133
134	134	135	136	137	137	139	141	141	143
145	148	149	149	149	150	150	153	153	153
153	154	157	160	160	162	163	163	165	165
167	167	168	170	171	172	173	174	175	175
176	178	178	178	179	179	179	180	181	181
181	182	182	185	185	186	186	187	188	188
188	189	189	191	191	191	192	192	194	194
194	194	195	196	197	197	198	198	198	199
200	201	202	204	204	205	205	206	207	210
214	214	215	215	216	217	218	219	219	221
221	221	221	221	222	223	223	224	227	227
228	229	232	234	234	238	240	242	242	242
244	246	253	253	255	258	282	290	314	319

$$x_{\min}=45,$$

$$x_{\max}$$

$$=319,$$

$$m_{0.5}$$

$$=181,$$

$$Q_1=144,$$

$$Q_3=212。$$



箱线图可用于对样本数据分布的形状进行大致的判断。

3、一本关于“统计图”的好书。

《现代统计图形》 谢益辉

<http://yihui.name/cn/publication/>

第一章 历史

- 1.1 饼图和线图的起源 . .
- 1.2 霍乱传染之谜
- 1.3 提灯女士的玫瑰图 . .
- 1.4 拿破仑的俄罗斯远征



第五章 图库

- 5.1 直方图
- 5.2 茎叶图
- 5.3 箱线图
- 5.4 条形图
- 5.5 散点图
- 5.6 关联图
- 5.7 条件密度图 . .
- 5.8 等高图
- 5.9 条件分割图 . .
- 5.10 一元函数曲线图

- 5.11 Cleveland点图
- 5.12 颜色等高图 . .
- 5.13 四瓣图
- 5.14 颜色图
- 5.15 矩阵图
- 5.16 马赛克图 . . .
- 5.17 散点图矩阵 . .
- 5.18 三维透视图 . .
- 5.19 因素效应图 . .
- 5.20 坐标轴须 . . .
- 5.21 平滑散点图 . .
- 5.22 棘状图
- 5.23 星状图
- 5.24 带状图

- 5.25 向日葵散点图 .
- 5.26 符号图
- 5.27 饼图
- 5.28 热图
- 5.29 交互效应图 . . .
- 5.30 QQ图
- 5.31 生存函数图 . . .
- 5.32 分类与回归树图
- 5.33 小提琴图
- 5.34 地图
- 5.35 脸谱图
- 5.36 平行坐标图 . . .
- 5.37 调和曲线图 . . .
- 5.38 二元箱线图 . . .

§6.3 抽样分布



经验分布函数

设 $X_1, X_2, \dots, X_n$ 是取自总体分布函数为 $F(x)$ 的样本, 若将样本观测值由小到大进行排列, 为 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$, 则称 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ 为**有序样本**.

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$

用有序样本定义如下函数

$$F_n(x) = \begin{cases} 0, & x < x_{(1)} \\ k/n, & x_{(k)} \leq x < x_{(k+1)}, \quad k=1, 2, \dots, n-1 \\ 1, & x_{(n)} \leq x \end{cases}$$


或 $F_n(x) = \frac{1}{n} s(x)$ $s(x)$ 表示 $x_1, x_2, \dots, x_n$ 中不大于 x 的随机变量的个数.

则 $F_n(x)$ 是一非减右连续函数, 且满足 $F_n(-\infty) = 0$ 和 $F_n(+\infty) = 1$

可见, $F_n(x)$ 是一个分布函数, 称 $F_n(x)$ 为**经验分布函数**.

$F_n(x)$ 的图形是累积频率曲线。它是跳跃上升的一条阶梯曲线。若观测值不重复，跃度为 $1/n$ ，若重复，按 $1/n$ 的倍数跳跃上升。

当 $n \rightarrow \infty$ 时, $F_n(x)$ 依概率收敛于总体的分布函数 $F(x)$



例 某食品厂生产听装饮料，现从生产线上
随机抽取5听饮料，称得其净重（单位：克）

351 347 355 344 351

这是一个容量为5的样本，经排序可得有序样本：

$$x_{(1)} = 344, x_{(2)} = 347, x_{(3)} = 351, x_{(4)} = 351, x_{(5)} = 355$$

其经验分布函数为

$$F_n(x) = \begin{cases} 0, & x < 344 \\ 0.2, & 344 \leq x < 347 \\ 0.4, & 347 \leq x < 351 \\ 0.8, & 351 \leq x < 355 \\ 1, & x \geq 355 \end{cases}$$

定理1 (格里文科定理)

对于任一实数 x , 当 $n \rightarrow \infty$ 时, $F_n(x)$ 以概率1一致收敛于分布函数 $F(x)$, 即

$$P\left\{\lim_{n \rightarrow \infty} \sup_{-\infty < x < +\infty} |F_n(x) - F(x)| = 0\right\} = 1.$$

对于任一实数 x 当 n 充分大时, 经验分布函数的任一个观察值 $F_n(x)$ 与总体分布函数 $F(x)$ 只有微小的差别, 从而在实际上可当作 $F(x)$ 来使用.

格里文科 (1933) 定理表明: 当 n 相当大时, 经验分布函数是总体分布函数 $F(x)$ 的一个良好的近似。

经典的统计学中一切统计推断都以样本为依据, 其理由就在于此。

统计量与抽样分布

当人们需要从样本获得对总体各种参数的认识时，最好的方法是构造样本的函数，不同的函数反映总体的不同特征。

定义6.3.1 设 $X_1, X_2, \dots, X_n$ 为取自某总体的样本，若样本函数 $T = T(X_1, X_2, \dots, X_n)$ 中不含有任何未知参数。则称 T 为**统计量**。统计量的分布称为**抽样分布**。

按照这一定义：若 $X_1, X_2, \dots, X_n$ 为样本，经验分布函数 $F_n(x)$ 是统计量。而当 μ, σ^2 未知时， $X_1 - \mu$, X_1/σ 等均不是统计量。

统计量既然是依赖于样本的，而后者又是随机变量，故统计量也是随机变量，因而就有一定的分布，这个分布叫做统计量的“**抽样分布**”。

抽样分布就是通常的随机变量函数的分布。只是强调这一分布是由统计量产生的。研究统计量的性质和评价一个统计推断的优良性，完全取决于其抽样分布的性质。

抽样分布 { **精确抽样分布** (小样本问题中使用)
渐近分布 (大样本问题中使用)

下面介绍一些常见的统计量及其抽样分布。

几个常见统计量

★样本均值

它反映了总体方差的信息

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

它反映了总体均值的信息

★样本方差

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

★样本标准差

$$S = \sqrt{S^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$$

它反映了总体 k 阶矩的信息

★样本 k 阶（原点）矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

★样本 k 阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$
 $k=1,2,\dots$

它反映了总体 k 阶中心矩的信息

样本均值的抽样分布：

定理6.3.3 设 $X_1, X_2, \dots, X_n$ 是来自某个总体的样本,
 $\bar{x}$ 为样本均值。

- (1) 若总体分布为 $N(\mu, \sigma^2)$, 则
 $\bar{X}$ 的精确分布为 $N(\mu, \sigma^2/n)$; 见教材142页。
- (2) 若总体分布未知或不是正态分布,
但 $E(x)=\mu$, $\text{Var}(x)=\sigma^2$, 则 n 较大时 $\bar{X}$ 的渐近分布为 $N(\mu, \sigma^2/n)$, 常记为 $\bar{X} \sim AN(\mu, \sigma^2/n)$ 。

这里渐近分布是指 n 较大时的近似分布。

样本方差的自由度：

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

在这个定义中， $\sum (x_i - \bar{x})^2$ 称为偏差平方和， $n-1$ 称为偏差平方和的自由度。其含义是：在 $\bar{x}$ 确定后， n 个偏差 $x_1 - \bar{x}, x_2 - \bar{x}, \dots, x_n - \bar{x}$ 中只有 $n-1$ 个数据可以自由变动，而第 n 个则不能自由取值，因为 $\sum (x_i - \bar{x}) = 0$ 。

矩统计量

若总体的 k 阶矩 $E(X^k) = \mu_k$ 存在, 则当 $n \rightarrow \infty$ 时,

$A_k \xrightarrow{P} \mu_k, k = 1, 2, \dots$. 这是因为 $X_1, X_2, \dots, X_n$ 独立且与 X 同分布, 所以 $X_1^k, X_2^k, \dots, X_n^k$ 独立且与 X^k 同分布, 故有

$$E(X_1^k) = E(X_2^k) = \dots = E(X_n^k) = \mu_k,$$

从而由第五章的辛钦定理知

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} \mu_k, \quad k = 1, 2, \dots$$

进而由第五章中关于依概率收敛的序列的性质

知道 $g(A_1, A_2, \dots, A_k) \xrightarrow{P} g(\mu_1, \mu_2, \dots, \mu_k),$

其中 g 为连续函数. 这是下一章所要介绍的矩估计法的理论根据.

上述五种统计量可统称为**矩统计量**, 简称**样本矩**, 他们都是样本的显函数, 它们的观测值仍分别称为样本均值、样本方差、样本标准差、样本**k**阶(原点)矩、样本**k**阶中心矩.

三大抽样分布

大家很快会看到，有很多统计推断是基于正态分布的假设的，以标准正态变量为基石而构造的三个著名统计量在实际中有广泛的应用，这是因为这三个统计量不仅有明确背景，而且其抽样分布的密度函数有明显表达式，它们被称为统计中的“三大抽样分布”。

1、 χ^2 分布(卡方分布)

定义1 设 $X_1, X_2, \dots, X_n$, 独立同分布于标准正态分布 $N(0,1)$, 则 $\chi^2 = X_1^2 + \dots + X_n^2$ 的分布称为自由度为 n 的 χ^2 分布, 记为 $\chi^2 \sim \chi^2(n)$ 。

χ^2 分布的密度函数为

$$f(x; n) = \begin{cases} \frac{1}{2^{n/2} \Gamma(n/2)} x^{\frac{n}{2}-1} e^{-\frac{x}{2}} & x \geq 0 \\ 0 & x < 0 \end{cases}$$


其中伽玛函数 $\Gamma(x)$ 通过积分

$$\Gamma(x) = \int_0^{\infty} e^{-t} t^{x-1} dt, \quad x > 0 \quad \text{来定义.}$$

该密度函数的图像
是一只取非负值的
偏态分布

$$E \chi^2 = n,$$

$$\text{Var}(\chi^2) = 2n$$



χ^2 分布的性质

性质1 (χ^2 分布的可加性)

设 $\chi_1^2 \sim \chi^2(n_1)$, $\chi_2^2 \sim \chi^2(n_2)$, 并且 χ_1^2 , χ_2^2 独立, 则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$.

(此性质可以推广到多个随机变量的情形)

设 $\chi_i^2 \sim \chi^2(n_i)$, 并且 χ_i^2 ($i = 1, 2, \dots, m$) 相互独立, 则 $\sum_{i=1}^m \chi_i^2 \sim \chi^2(n_1 + n_2 + \dots + n_m)$.

性质2 (χ^2 分布的数学期望和方差)

若 $\chi^2 \sim \chi^2(n)$, 则 $E(\chi^2) = n$, $D(\chi^2) = 2n$.

证明

事实上, 因 $X_i \sim N(0,1)$, 故

$$E(X_i^2) = D(X_i) = 1$$

$$D(X_i^2) = E(X_i^4) - [E(X_i^2)]^2 = 3 - 1 = 2$$

$i = 1, 2, \dots, n$

$$E(\chi^2) = E\left(\sum_{i=1}^n X_i^2\right) = \sum_{i=1}^n E(X_i^2) = n$$

$$D(\chi^2) = D\left(\sum_{i=1}^n X_i^2\right) = \sum_{i=1}^n D(X_i^2) = 2n$$


χ^2 分布的上侧分位数 $\chi_{\alpha}^2(n)$

对于给定的正数 α , $0 < \alpha < 1$, 称满足条件

$$P\{\chi^2 > \chi_{\alpha}^2(n)\} = \alpha$$

的点 $\chi_{\alpha}^2(n)$ 为 $\chi^2(n)$ 分布的上 α 分位数 (分位点).

对于不同的 α, n ,
可以通过查表求
得上 α 分位点的值.



附表

χ^2 分布表

n	$\alpha = 0.25$	0.10	0.05	0.025	0.01	0.005
1	1.323	2.706	3.841	5.024	6.635	7.879
2	2.773			5.978	9.210	10.597
3	4.108			7.878	11.345	12.838
4	5.385			9.488	13.277	14.860
5	6.626			11.143	15.086	16.750
6	7.841			12.733	16.812	18.548
7	9.037			14.449	18.475	20.278
8	10.219			16.151	20.090	21.955
9	11.389	14.684	16.919	17.923	21.666	23.589
10	12.549	15.987	18.307	20.483	23.209	25.188
11	13.701	17.275	19.675	21.920	24.725	26.757
12	14.845	18.549	21.026	23.337	26.217	28.299
13	15.984	19.812	22.362	24.736	27.688	29.891
14	17.117	20.064	23.685	26.119	29.141	31.319
15	18.245	22.307	24.996	27.488	30.578	32.801
16	19.369	23.542	26.296	28.845	32.000	34.267

$$\chi^2_{0.025}(11) = 21.920$$

2、 F 分布

定义： 设 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, X 与 Y 相互独立，则称统计量

$$F = \frac{X/n_1}{Y/n_2}$$

服从自由度为 n_1 及 n_2 的 F 分布， n_1 称为第一自由度， n_2 称为第二自由度，记作 $F \sim F(n_1, n_2)$.

若 $X \sim F(n_1, n_2)$, X 的概率密度为

$$f(x; n_1, n_2) = \begin{cases} \frac{\Gamma(\frac{n_1+n_2}{2})}{\Gamma(\frac{n_1}{2}) \Gamma(\frac{n_2}{2})} \left(\frac{n_1}{n_2}\right) \left(\frac{n_1}{n_2} x\right)^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2} x\right)^{-\frac{n_1+n_2}{2}} & x \geq 0 \\ 0 & x < 0 \end{cases}$$


F 分布有以下性质

(1) 若 $F \sim F(n_1, n_2)$,
则 $\frac{1}{F} \sim F(n_2, n_1)$.

(2)
$$E(F) = \frac{n_2}{n_2 - 2}, \quad (n_2 > 2),$$

$$D(F) = \frac{2n_2^2(n_1 + n_2 - 2)}{n_1(n_2 - 2)^2(n_2 - 4)}, \quad (n_2 > 4)$$

即它的数学期望并不依赖于第一自由度 n_1 .



(3) 设 $F \sim F(n_1, n_2)$, 则当 $n_2 > 4$ 时, 对任意 x 有

$$\lim_{n_1 \rightarrow \infty} P\left\{\frac{F - E(F)}{\sqrt{D(F)}} \leq x\right\} = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

注意

- 这说明 F 分布极限分布也是正态分布.


F 分布的上侧分位数 $F_{\alpha}(n_1, n_2)$

对于给定的 α , $0 < \alpha < 1$, 称满足条件

$$P\{F > F_{\alpha}(n_1, n_2)\} = \alpha$$

的点 $F_{\alpha}(n_1, n_2)$ 为 $F(n_1, n_2)$ 分布的上 α 分位数.

求 $F_{\alpha}(n_1, n_2)$ 的值, 可通过查表完成.



由 F 分布的构造知 $F_{\alpha}(n, m) = 1/F_{1-\alpha}(m, n)$ 。

3、 t 分布

定义3 设随机变量 X_1 与 X_2 独立,

且 $X_1 \sim N(0,1)$, $X_2 \sim \chi^2(n)$, 则称 $t = X_1/\sqrt{X_2/n}$

的分布为自由度为 n 的 t 分布, 记为 $t \sim t(n)$ 。

自由度为 n 的 t 分布的密度函数为:

$$h(x) = \frac{\Gamma[(n+1)/2]}{\Gamma(n/2)\sqrt{n\pi}} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$$

t 分布是科塞特 (W.S.Gosset) 于 1908 年在一篇署名为“学生” (Student) 的论文中首先提出来的, 因此, t 分布也称为 “**学生氏分布**”。


t 分布的概率密度曲线如图

显然图形是关于

$t = 0$ 对称的.

当 n 充分大时, 其图形类似于标准正态变量概率密度的图形.

因为 $\lim_{n \rightarrow \infty} h(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}},$



所以当 n 足够大时 t 分布近似于 $N(0,1)$ 分布,
但对于较小的 n , t 分布与 $N(0,1)$ 分布相差很大.

t 分布的上侧分位数 $t_{\alpha}(n)$

对于给定的 α , $0 < \alpha < 1$, 称满足条件

$$P\{t > t_{\alpha}(n)\} = \alpha$$


的点 $t_{\alpha}(n)$ 为 $t(n)$ 分布的上 α 分位数(或分位点).

可以通过查表求得
上 α 分位数的值.

由分布的对称性知

$$t_{1-\alpha}(n) = -t_{\alpha}(n).$$

当 $n > 45$ 时, $t_{\alpha}(n) \approx z_{\alpha}$.



4、一些重要结论

正态总体样本均值与方差的分布

当总体为正态分布时，教材上给出了几个重要的抽样分布定理。这里我们不证明，定理的证明都可以在教材上找到。

定理1 设 $x_1, x_2, \dots, x_n$ 是来自 $N(\mu, \sigma^2)$ 的样本，其样本均值和样本方差分别为

$$\bar{x} = \sum x_i / n \quad \text{和} \quad s^2 = \sum (x_i - \bar{x})^2 / (n-1)$$

则有 (1) $\bar{x} \sim N(\mu, \sigma^2/n)$; 样本均值的分布

(2) $\bar{x}$ 与 s^2 相互独立;

(3) $(n-1) s^2 / \sigma^2 \sim \chi^2(n-1)$ 。样本方差的分布

(4) $(\bar{x} - \mu) / (s / \sqrt{n}) \sim t(n-1)$ 。

定理(4)证明 设 $X_1, X_2, \dots, X_n$ 为来自总体 $N(\mu, \sigma^2)$ 的样本,
 $\bar{X}, S^2$ 分别为样本均值与样本方差, 则有

$$\frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n - 1)$$

证：由定理(3)的结论知

$$\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0,1), \frac{(n - 1)S^2}{\sigma^2} \sim \chi^2(n - 1)$$

且 $\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$ 与 $\frac{(n - 1)S^2}{\sigma^2}$ 相互独立, 由 t 分布的定义知

$$\frac{\bar{X} - \mu}{S / \sqrt{n}} = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}} / \sqrt{\frac{(n - 1)S^2}{\sigma^2(n - 1)}} \sim t(n - 1)$$

两总体样本方差比的分布

推论3 设 $x_1, x_2, \dots, x_m$ 是来自 $N(\mu_1, \sigma_1^2)$ 的样本, $y_1, y_2, \dots, y_n$ 是来自 $N(\mu_2, \sigma_2^2)$ 的样本, 且此两样本相互独立, 则有

$$F = \frac{s_x^2 / \sigma_1^2}{s_y^2 / \sigma_2^2} \sim F(m-1, n-1)$$

特别, 若 $\sigma_1^2 = \sigma_2^2$, 则

$$F = s_x^2 / s_y^2 \sim F(m-1, n-1)$$

两总体样本均值差的分布

推论4 在推论3的记号下, 设

$$\sigma_1^2 = \sigma_2^2 = \sigma^2,$$

并记

$$s_w^2 = \frac{(m-1)s_x^2 + (n-1)s_y^2}{m+n-2} = \frac{\sum_{i=1}^m (x_i - \bar{x})^2 + \sum_{i=1}^n (y_i - \bar{y})^2}{m+n-2}$$

则

$$\frac{(\bar{x} - \bar{y}) - (\mu_1 - \mu_2)}{s_w \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2)$$

练习 设 X_1, X_2, X_3 是来自总体 $N(\mu, \sigma^2)$ 的一个样本, 其中 μ 为已知, σ^2 为未知, 判断下列各式哪些是统计量, 哪些不是?

$$T_1 = X_1,$$

$$T_2 = X_1 + X_2 e^{X_3},$$

$$T_3 = \frac{1}{3}(X_1 + X_2 + X_3),$$

$$T_4 = \max(X_1, X_2, X_3), \quad T_5 = X_1 + X_2 - 2\mu,$$

是

$$T_6 = \frac{1}{\sigma^2}(X_1^2 + X_2^2 + X_3^2).$$

不是

次序统计量*

设 $x_1, x_2, \dots, x_n$ 是取自总体 X 的样本,
 $x_{(i)}$ 称为该样本的第 i 个次序统计量, 它的取值
是将样本观测值由小到大排列后得到的第 i 个
观测值。其中 $x_{(1)} = \min\{x_1, x_2, \dots, x_n\}$ 称为该样本
的最小次序统计量, 称 $x_{(n)} = \max\{x_1, x_2, \dots, x_n\}$ 为
该样本的最大次序统计量。

样本中位数是次序统计量的函数,

我们知道，在一个样本中， $x_1, x_2, \dots, x_n$ 是独立同分布的，而次序统计量 $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ 则既不独立，分布也不相同，看下例。

例 设总体 X 的分布为仅取0, 1, 2的离散均匀分布，分布列为

x	0	1	2
p	1/3	1/3	1/3

现从中抽取容量为3的样本，其一切可能取值有 $3^3=27$ 种，表5.3.6列出了这些值，由此

可给出的 $x_{(1)}, x_{(2)}, x_{(3)}$ 分布列如

$x_{(1)}$	0	1	2
p	$\frac{19}{27}$	$\frac{7}{27}$	$\frac{1}{27}$

$x_{(2)}$	0	1	2
p	$\frac{7}{27}$	$\frac{13}{27}$	$\frac{7}{27}$

$x_{(3)}$	0	1	2
p	$\frac{1}{27}$	$\frac{7}{27}$	$\frac{19}{27}$

我们可以清楚地看到这三个次序统计量的分布是不相同的。

进一步，我们可以给出两个次序统计量的联合分布，如， $x_{(1)}$ 和 $x_{(2)}$ 的联合分布列为

$x_{(1)} \quad x_{(2)}$	0	1	2
0	$7/27$	$9/27$	$3/27$
1	0	$4/27$	$3/27$
2	0	0	$1/27$

因为 $P(x_{(1)} = 0, x_{(2)} = 0) = 7/27$,

而

$$P(x_{(1)} = 0) * P(x_{(2)} = 0) = (19/27) * (7/27),$$

二者不等,

由此可看出 $x_{(1)}$ 和 $x_{(2)}$ 是不独立的。

单个次序统计量的分布*

定理2 设总体 X 的密度函数为 $p(x)$, 分布函数为 $F(x)$, $x_1, x_2, \dots, x_n$ 为样本, 则第 k 个次序统计量 $x_{(k)}$ 的密度函数为

$$p_k(x) = \frac{n!}{(k-1)!(n-k)!} (F(x))^{k-1} (1-F(x))^{n-k} p(x)$$

多个次序统计量的联合分布*

对任意多个次序统计量可给出其联合分布，以两个为例说明：

定理3 在定理2的符号定义下，次序统计量 $(x_{(i)}, x_{(j)}), (i < j)$ 的联合分布密度函数为

$$p_{ij}(y, z) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} [F(y)]^{i-1} [F(z) - F(y)]^{j-i-1} \cdot [1 - F(z)]^{n-j} p(y)p(z), \quad y \leq z$$

次序统计量的函数在实际中经常用到。

如

样本极差 $R_n = x_{(n)} - x_{(1)}$,

样本中程 $[x_{(n)} - x_{(1)}]/2$ 。

样本极差是一个很常用的统计量，其分布只在很少几种场合可用初等函数表示。

第六章思维导图

样本及抽样分布

随机样本

总体

样本

简单随机样本

随机性

独立性

直方图与箱线图

直方图

箱线图

样本分位数

修正箱线图

经验分布函数

$$F_n(x) = s(x)/n \quad s(x) \text{ 表示 } x_1, \dots, x_n \text{ 中不大于 } x \text{ 的随机变量个数}$$

格里汶科定理

统计量 $T(X_1, \dots, X_n)$ 不含任何未知参数

$$\text{样本均值 } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{样本方差 } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$\text{样本标准差 } S = \sqrt{S^2}$$

$$\text{样本 } k \text{ 阶 (原点) 矩 } A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

$$\text{样本 } k \text{ 阶中心矩 } B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

抽样分布

抽样分布：统计量的分布

卡方分布 $\chi^2(n)$: n 个独立标准正态分布的平方和

期望 = n

方差 = $2n$

可加性

t 分布: 设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, X 与 Y 独立, 则 $T = \frac{X}{\sqrt{Y/n}} \sim t(n)$

F 分布: 设 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$, X 与 Y 独立, 则 $F = \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$

若 $F \sim F(n_1, n_2)$, 则 $1/F \sim F(n_2, n_1)$

$$E(F) = \frac{n_2}{n_2 - 2}, \quad (n_2 > 2)$$

$$D(F) = \frac{2n_1^2(n_1 + n_2 - 2)}{n_1(n_2 - 2)^2(n_2 - 4)}, \quad (n_2 > 4)$$

正态总体样本均值与方差的分布:
设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu_1, \sigma_1^2)$ 的样本,
 $Y_1, Y_2, \dots, Y_m$ 是来自 $N(\mu_2, \sigma_2^2)$ 的样本,

$$\bar{X} \sim N(\mu_1, \sigma_1^2/n)$$

$\bar{X}$ 与 S_X^2 相互独立

$$(n-1)S_X^2/\sigma_1^2 \sim \chi^2(n-1)$$

$$(\bar{X} - \mu_1)/(S_X/\sqrt{n}) \sim t(n-1)$$

$$\frac{S_X^2/\sigma_1^2}{S_Y^2/\sigma_2^2} \sim F(n-1, m-1)$$

$$\text{若 } \sigma_1^2 = \sigma_2^2, \text{ 记 } S_w^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}, \text{ 则 } T = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t(n+m-2)$$



第六章作业 (05/31)

《概率论与数理统计》 (第五版) 第六章
课后习题: 2, 4, 6, 9, 10

